

Mini Project - Pemrosesan Bahasa Alami

Nama Kelompok : [dikosongi]

Anggota :

[202310370311127 – Fakhar Hanif]

[202310370311147 - Sherlin Wulandari]

[202310370311113 - Annisa Qurrata A'yun]

Berikut ini merupakan update template laporan Mini Project kuliah Pemrosesan Bahasa Alami.

Tahap 0 (poin: 25): Business Objective

1. Urgensi

Industri wine global menunjukkan perkembangan yang pesat dengan tingkat persaingan yang semakin tinggi, ditandai oleh beragamnya produk, variasi harga, serta preferensi konsumen yang dinamis. Dataset wine review yang digunakan, yang mencakup lebih dari 130.000 data observasi, merepresentasikan kompleksitas pasar tersebut melalui atribut seperti negara asal, varietas, winery, harga, serta penilaian kualitas. Tanpa adanya analisis yang sistematis, pelaku bisnis akan menghadapi kesulitan dalam memahami pola pasar dan perilaku konsumen. Oleh karena itu, pemanfaatan data ini menjadi krusial untuk mendukung pengambilan keputusan yang berbasis bukti (data-driven decision making).

2. Problem Framing

Permasalahan utama dalam penelitian ini adalah bagaimana mengklasifikasikan kualitas wine berdasarkan teks deskripsi yang diberikan oleh reviewer. Selain itu, terdapat tantangan dalam mengolah data deskriptif yang bersifat subjektif menjadi informasi yang dapat digunakan dalam proses klasifikasi menggunakan pendekatan Natural Language Processing (NLP).

3. Potential Solution

Untuk menjawab permasalahan tersebut, dilakukan pendekatan analisis data

eksploratif (EDA) untuk memahami karakteristik data. Selanjutnya, diterapkan teknik Natural Language Processing (NLP) untuk mengolah data teks pada atribut *description*. Data teks pada atribut *description* kemudian diproses menggunakan tahapan Natural Language Processing (NLP), mulai dari preprocessing, representasi fitur teks, hingga pemodelan klasifikasi. Representasi fitur yang digunakan meliputi Bag of Words (BoW), TF-IDF, N-Gram, Word2Vec, FastText, GloVe, dan BERT. Selanjutnya dilakukan proses balancing dan evaluasi menggunakan beberapa algoritma machine learning untuk memperoleh performa terbaik, dan digunakan dalam model machine learning untuk mengklasifikasikan kualitas wine ke dalam beberapa kategori.

4. Impact dari Solusi

Implementasi solusi berbasis analisis data ini diharapkan dapat memberikan dampak signifikan terhadap peningkatan kualitas pengambilan keputusan bisnis. Perusahaan dapat mengidentifikasi faktor utama yang memengaruhi preferensi konsumen, mengoptimalkan strategi penetapan harga, serta meningkatkan kualitas dan positioning produk di pasar. Selain itu, hasil klasifikasi kualitas wine berbasis teks deskripsi juga dapat membantu dalam memahami persepsi konsumen terhadap produk berdasarkan ulasan yang diberikan. Pengembangan sistem rekomendasi berbasis data ini berpotensi meningkatkan pengalaman pelanggan serta mendorong peningkatan penjualan dan loyalitas konsumen.

5. Strategic Value

Secara strategis, pemanfaatan data ini juga dapat mendukung perencanaan jangka panjang, seperti identifikasi peluang ekspansi pasar, pengembangan produk baru yang sesuai dengan tren konsumen, serta optimalisasi portofolio produk. Dengan pendekatan berbasis data, perusahaan tidak hanya mampu meningkatkan daya saing, tetapi juga memiliki kemampuan adaptasi yang lebih baik terhadap perubahan dinamika pasar. Selain itu, penerapan metode Natural Language Processing (NLP) dalam mengklasifikasikan kualitas wine membuka peluang pengembangan sistem analitik berbasis teks yang lebih canggih, seperti sistem rekomendasi produk yang mampu memahami preferensi konsumen secara lebih akurat.

Tahap 1 (poin: 25): Original Data

No	country	descript ion	designatio n	poin ts	price	provi nce	region _1	region _2	taster_name	taster_twitter_ha ndle	title	variety	winery
0	Italy	Aromas include tropical fruit, broom, brimstone and dried herb. The palate isn't overly expressive...	Vulkà Bianco	87	NaN	Sicily & Sardinia	Etna	NaN	Kerin O'Keefe	@kerinokeefe	Nicosia 2013 Vulkà Bianco (Etna)	White Blend	Nicosia
1	Portugal	This is ripe and fruity, a wine that is smooth while	Avidagos	87	15.0	Douro	NaN	NaN	Roger Voss	@vossroger	Quinta dos Avidagos 2011 Avidagos Red (Douro)	Portuguese Red	Quinta dos Avidagos

		still structur ed...											
2	US	Tart and snappy, the flavors of lime flesh and rind dominat e...	NaN	87	14.0	Oreg on	Willa mette Valley	Willa mette Valley	Paul Gregut t	@paulgwine	Rainstor m 2013 Pinot Gris (Willame tte Valley)	Pinot Gris	Rainstor m
3	US	Pineapp le rind, lemon pith and orange blossom start off the aromas. ..	Reserve Late Harvest	87	13.0	Mich igan	Lake Michig an Shore	NaN	Alexander Peartree	NaN	St. Julian 2013 Reserve Late Harvest Riesling (Lake Michiga n Shore)	Riesling	St. Julian

4	US	Much like the regular bottling from 2012, this comes across as rather rough...	Vintner's Reserve Wild Child Block	87	65.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paulgwine	Sweet Cheeks 2012 Vintner's Reserve Wild Child Block Pinot Noir (Willamette Valley)	Pinot Noir	Sweet Cheeks
5	Spain	Blackberry and raspberry aromas show a typical Navarran heft...	Ars In Vitro	87	15.0	Northern Spain	Navarra	NaN	Michael Schachner	@wineschach	Tandem 2011 Ars In Vitro Tempranillo-Merlot (Navarra)	Tempranillo-Merlot	Tandem

6	Italy	Here's a bright, informal red that opens with aromas of candied berry...	Belsito	87	16.0	Sicily & Sardinia	Vittoria	NaN	Kerin O'Keefe	@kerinokeefe	Terre di Giurfo 2013 Belsito Frappato (Vittoria)	Frappato	Terre di Giurfo
7	France	This dry and restrained wine offers spice in profusion...	Gewurztraminer	87	24.0	Alsace	Alsace	NaN	Roger Voss	@vossroger	Trimbach 2012 Gewurztraminer (Alsace)	Gewurztraminer	Trimbach
8	Germany	Savory dried thyme notes accent sunnier	Shine	87	12.0	Rheinhessen	NaN	NaN	Anna Lee C. Iijima	NaN	Heinz Eifel 2013 Shine Gewurztraminer	Gewurztraminer	Heinz Eifel

		flavors of preserv ed peach...									(Rheinhe ssen)		
9	France	This has great depth of flavor with its fresh apple and pear fruits...	Les Natures	87	27.0	Alsa ce	Alsace	NaN	Roger Voss	@vossroger	Jean-Bap tiste Adam 2012 Les Natures Pinot Gris (Alsace)	Pinot Gris	Jean-Bapt iste Adam

Dataset yang digunakan dalam penelitian ini adalah dataset review wine berbasis teks yang digunakan untuk analisis Natural Language Processing (NLP). Dataset ini dikenal dengan nama Wine Reviews Dataset yang diperoleh dari Kaggle melalui tautan <https://www.kaggle.com/datasets/zynicide/wine-reviews>. Dataset tersebut memiliki sekitar 130.000 baris data dengan total 13 atribut. Jenis data yang terdapat dalam dataset ini bersifat campuran, yaitu terdiri dari data teks (unstructured), data numerik, dan data kategorikal. Kombinasi jenis data ini menjadikan dataset sangat cocok untuk analisis berbasis NLP sekaligus eksplorasi data secara menyeluruh.

Secara karakteristik, dataset ini memiliki tipe data yang beragam. Data teks yang menjadi komponen utama dalam analisis adalah atribut description, yang berisi ulasan atau deskripsi wine. Selain itu, terdapat data kategorikal seperti country, province, region_1, region_2, variety, winery, dan taster_name yang memberikan informasi terkait asal, jenis, dan pihak yang terlibat dalam penilaian wine. Dataset ini juga memiliki data numerik, yaitu points yang menunjukkan skor kualitas wine dan price yang menunjukkan harga wine. Ciri khusus dari dataset ini adalah dominasi data teks yang tidak terstruktur, dengan panjang deskripsi yang bervariasi serta mengandung banyak kata deskriptif seperti flavor dan aroma. Hal ini membuat dataset sangat sesuai digunakan dalam tugas klasifikasi teks menggunakan metode NLP.

No	Atribut	Tipe Data	Nilai Minimum	Nilai Maksimum	Rata-rata	Jumlah Unik
1	points	Numerik	80	100	88.45	-
2	price	Numerik	4	3300	35.36	-
3	country	Kategorikal	-	-	-	43
4	variety	Kategorikal	-	-	-	707
5	winery	Kategorikal	-	-	-	16,757

Berdasarkan tabel statistik deskriptif di atas, dapat dilihat bahwa atribut points memiliki rentang nilai antara 80 hingga 100 dengan rata-rata sebesar 88,45, yang menunjukkan bahwa sebagian besar wine dalam dataset memiliki kualitas yang relatif tinggi. Sementara itu, atribut price memiliki rentang yang sangat luas, yaitu dari 4 hingga 3300 USD, dengan rata-rata sebesar 35,36 USD, yang mengindikasikan adanya perbedaan harga yang cukup signifikan antar produk. Selain itu, atribut kategorikal seperti country, variety, dan winery memiliki jumlah kategori yang cukup besar, yaitu masing-masing sebanyak 43, 707, dan 16.757, sehingga menunjukkan bahwa dataset memiliki tingkat keberagaman yang tinggi dan kompleksitas yang cukup besar untuk dianalisis.

No	Atribut	Jumlah Missing	Persentase
1	region_2	79,46	61.14%
2	designation	37,465	28.83%
3	taster_twitter_handle	31,213	24.02%
4	taster_name	26,244	20.19%
5	region_1	21,247	16.35%
6	price	8,996	6.92%
7	country	63	0.05%
8	province	63	0.05%

Berdasarkan hasil analisis missing value, terlihat bahwa beberapa atribut memiliki jumlah data kosong yang cukup tinggi. Atribut region_2 memiliki persentase missing value paling besar, yaitu sebesar 61,14%, diikuti oleh designation dan taster_twitter_handle. Hal ini menunjukkan bahwa tidak semua informasi terkait detail lokasi dan reviewer tersedia secara lengkap dalam dataset. Selain itu, atribut price juga memiliki missing value sebesar 6,92%, yang perlu diperhatikan karena berkaitan dengan nilai ekonomi produk. Sementara itu, atribut seperti country dan province memiliki jumlah missing value yang sangat kecil sehingga tidak memberikan pengaruh signifikan terhadap analisis. Tingginya missing value pada beberapa atribut menunjukkan bahwa tidak semua fitur layak digunakan dalam proses analisis, sehingga diperlukan seleksi fitur agar model yang dibangun tetap optimal dan tidak dipengaruhi oleh data yang tidak lengkap.

Tahap 2 (poin: 10): Target Data (Optional)

Pada tahap ini dilakukan pemilihan atribut yang akan digunakan dalam proses data mining. Hal ini dilakukan karena tidak semua atribut dalam dataset relevan terhadap tujuan analisis, terutama dalam konteks Natural Language Processing (NLP) yang berfokus pada data teks.

No	Nama Atribut	Keterangan
1	Description	Teks review atau deskripsi wine
2	Points	Skor kualitas wine

Pemilihan atribut dalam penelitian ini dilakukan berdasarkan keterkaitannya dengan tujuan utama, yaitu melakukan klasifikasi kualitas wine berbasis teks. Oleh karena itu, atribut yang dipilih harus mampu merepresentasikan informasi yang relevan untuk proses analisis *Natural Language Processing* (NLP) sekaligus mendukung pembentukan model klasifikasi yang efektif.

Atribut *description* dipilih sebagai atribut utama karena berisi data teks yang menggambarkan karakteristik wine secara deskriptif, seperti rasa, aroma, tekstur, dan kesan keseluruhan. Informasi ini sangat penting dalam konteks NLP karena dapat diolah menjadi fitur numerik menggunakan metode seperti *Bag of Words*, *N-gram*, dan *TF-IDF*.

Dengan demikian, atribut ini menjadi sumber utama dalam proses ekstraksi informasi yang akan digunakan oleh model untuk memahami pola dan hubungan dalam data.

Sementara itu, atribut *points* digunakan sebagai variabel target karena merepresentasikan kualitas wine dalam bentuk skor numerik yang diberikan oleh reviewer. Nilai ini dapat digunakan untuk menentukan kelas kualitas wine yang akan diprediksi oleh model, sehingga sangat relevan dengan tujuan klasifikasi yang ingin dicapai dalam penelitian ini.

Di sisi lain, atribut seperti *country*, *price*, *winery*, dan *variety* tidak digunakan karena tidak sesuai dengan fokus utama analisis yang berbasis teks. Atribut-atribut tersebut tidak secara langsung berkontribusi dalam proses klasifikasi berbasis NLP dan berpotensi menambah kompleksitas model tanpa memberikan peningkatan performa yang signifikan. Oleh karena itu, penggunaan dua atribut utama, yaitu *description* dan *points*, dinilai sudah cukup untuk membangun model klasifikasi kualitas wine berbasis teks secara optimal.

Target Data

Target yang digunakan dalam penelitian ini adalah:

No	Nama Target	Keterangan
1	Points	Skor kualitas wine yang akan diklasifikasikan

Transformasi Target

Karena nilai *points* berupa numerik, maka dilakukan transformasi menjadi kategori untuk keperluan klasifikasi:


Rentang Points	Kategori
≤ 85	Low
86 – 90	Medium
> 90	High

Alasan Pemilihan Target

Pemilihan atribut *points* sebagai target dalam penelitian ini didasarkan pada kemampuannya dalam merepresentasikan kualitas wine secara langsung melalui skor yang diberikan oleh reviewer. Nilai tersebut mencerminkan tingkat kualitas produk sehingga sangat relevan untuk dijadikan sebagai acuan dalam proses klasifikasi. Selain itu, atribut *points* yang awalnya berbentuk numerik dapat dengan mudah ditransformasikan menjadi kelas-kelas kategori, sehingga sesuai untuk digunakan dalam metode klasifikasi. Pemilihan target ini juga sejalan dengan tujuan penelitian, yaitu mengklasifikasikan kualitas wine berdasarkan teks review, sehingga model yang dibangun dapat memanfaatkan informasi deskriptif untuk memprediksi tingkat kualitas secara efektif.

Distribusi Kelas Target

No	Kategori	Rentang Points	Jumlah Data	Persentase
1	Low	≤ 85	27,315	21.02%
2	Medium	86 – 90	78,564	60.42%
3	High	> 90	24,092	18.56%
	Total	-	129,971	100%



Berdasarkan distribusi kategori kualitas wine, terlihat bahwa kategori Medium mendominasi dataset dengan persentase sebesar 57,2%, sedangkan kategori Low dan High memiliki jumlah data yang lebih rendah, yaitu masing-masing sebesar 16,9% dan 25,9%. Kondisi ini menunjukkan bahwa dataset berada pada keadaan imbalanced dataset (data tidak seimbang) karena distribusi antar kelas tidak proporsional. Ketidakeimbangan tersebut berpotensi menyebabkan model lebih cenderung memprediksi kelas mayoritas dan menurunkan kemampuan klasifikasi pada kelas minoritas. Oleh karena itu, pada tahap eksperimen dilakukan proses balancing data setelah representasi teks untuk meningkatkan kemampuan model dalam mengenali seluruh kategori secara lebih merata.

Data Selection & Sampling

Setelah dilakukan analisis distribusi kelas, tahap berikutnya adalah data selection dan sampling. Pada tahap data selection, atribut yang digunakan dalam penelitian dipilih berdasarkan kebutuhan proses klasifikasi teks. Dari keseluruhan atribut yang tersedia, hanya atribut *description* dan *quality_label* yang digunakan. Atribut *description* berisi ulasan teks mengenai karakteristik wine yang menjadi sumber informasi utama dalam proses Natural Language Processing (NLP), sedangkan *quality_label* digunakan sebagai target kelas yang akan diprediksi.

Selanjutnya dilakukan proses sampling untuk mengurangi ukuran dataset sehingga proses eksperimen dapat dilakukan dengan lebih efisien tanpa menghilangkan karakteristik utama data. Dari dataset hasil seleksi, diambil sebanyak 10.000 data sebagai sampel penelitian.

Hasil sampling menghasilkan dataset yang hanya terdiri dari dua atribut, yaitu *description* dan *quality_label*. Dataset inilah yang kemudian digunakan pada tahap preprocessing, representasi teks, balancing data, dan proses klasifikasi.

Tabel Perubahan Atribut Setelah Selection dan Sampling

Tahap	Jumlah Atribut	Atribut
Sebelum Selection	14	country, description, designation, points, price, province, region_1, region_2, taster_name, taster_twitter_handle, title, variety, winery, quality_label
Setelah Selection & Sampling	2	description, quality_label

Data Pre-processing

Pada tahap ini dilakukan proses data preprocessing yang bertujuan untuk membersihkan serta menyiapkan data sebelum digunakan dalam proses analisis lebih lanjut. Preprocessing menjadi langkah penting dalam Natural Language Processing (NLP) karena data teks yang digunakan masih bersifat tidak terstruktur dan mengandung berbagai noise seperti tanda baca, kata tidak penting, serta variasi penulisan yang dapat memengaruhi performa model.

Pada tahap awal dilakukan pemilihan atribut yang digunakan pada penelitian. Dari seluruh atribut dataset hanya dipilih:

Tabel Before

Unnamed: 0	Country	Description	Designation	Points	Price	Province	Region_1	Region_2	Taster_Name	Taster_Twitter_Handle	Title	Variety	Winery
------------	---------	-------------	-------------	--------	-------	----------	----------	----------	-------------	-----------------------	-------	---------	--------

Tabel After

Description	Points
-------------	--------

Selanjutnya dilakukan pengecekan terhadap missing value pada dataset. Berdasarkan hasil pemeriksaan, tidak ditemukan data yang memiliki nilai kosong pada kedua kolom tersebut, sehingga tidak dilakukan proses penghapusan data pada tahap ini.

Kolom	Jumlah_Missing_Value
Description	0
Points	0

Setelah itu, dilakukan penghapusan data duplikat untuk menghindari bias dalam proses analisis. Hasilnya, sejumlah data duplikat berhasil dihapus sehingga dataset menjadi lebih representatif.

Jumlah_Data_Duplikat	Jumlah_Data_Setelah_Penghapusan
129971	119974

Setelah proses pembersihan awal, dilakukan tahap preprocessing teks yang dimulai dengan proses case folding. Pada tahap ini, seluruh huruf dalam teks diubah menjadi huruf kecil untuk menghindari perbedaan representasi kata akibat penggunaan huruf kapital. Hasil dari proses ini dapat dilihat pada Tabel

Before	After
Good Cab, maybe a touch herbal and light, but very solid. Early aromas of cola, leather and blackberry show some herbal, green notes. But the tomato leaf character is not dominant or unappealing, thus in the end this displays classic Chilean Cabernet qualities on a light, agile frame. Drink now.	good cab, maybe a touch herbal and light, but very solid. early aromas of cola, leather and blackberry show some herbal, green notes. but the tomato leaf character is not dominant or unappealing, thus in the end this displays classic chilean cabernet qualities on a light, agile frame. drink now.
The former race car driver hired Doug Margerum to make his wine. Though quite pale in color, this offers fragrant aromas of sea salt, rounded nectarine fruit, wisps of white flowers and the slightest show of almond macarons. Stone fruit pops out on the salty palate, but the bright acidity and chalky minerality slice deeply, ending on a dollop of vanilla cream.	the former race car driver hired doug margerum to make his wine. though quite pale in color, this offers fragrant aromas of sea salt, rounded nectarine fruit, wisps of white flowers and the slightest show of almond macarons. stone fruit pops out on the salty palate, but the bright acidity and chalky minerality slice deeply, ending on a dollop of vanilla cream.
Here's a fruit-packed white wine bursting with flavors of peach and pear. The blend of 62% Muscat and 38% Viognier works beautifully. If you want plenty of fruit, a bit of sweetness, but enough acid to support a	here's a fruit-packed white wine bursting with flavors of peach and pear. the blend of 62% muscat and 38% viognier works beautifully. if you want plenty of fruit, a bit of sweetness, but enough acid to support a

food-friendly white wine, this is your bottle.	food-friendly white wine, this is your bottle.
This stalky, tight wine has a smoky character, lean black-currant fruits and a tough, possibly unripe fruitiness. It is developing fast, drink from 2017.	this stalky, tight wine has a smoky character, lean black-currant fruits and a tough, possibly unripe fruitiness. it is developing fast, drink from 2017.
This Shiraz has a plucky nose of tart cherry, tobacco and pepper. The flavors of clove, tobacco and berry on the palate are fruity but balanced by the spice. Pair with cheeses, lamb.	this shiraz has a plucky nose of tart cherry, tobacco and pepper. the flavors of clove, tobacco and berry on the palate are fruity but balanced by the spice. pair with cheeses, lamb.

Selanjutnya dilakukan penghapusan tanda baca (punctuation removal). Tanda baca seperti titik, koma, dan simbol lainnya dihilangkan karena tidak memberikan kontribusi signifikan dalam proses analisis teks.

Hasil perubahan sebelum dan sesudah proses ini ditunjukkan pada Tabel

Before	After
freshly ground black pepper and dark cherries scent this hungarian kékfrankos. it is medium bodied, presenting flavors of pomegranate and sour cherry with a slightly tart finish.	freshly ground black pepper and dark cherries scent this hungarian kékfrankos it is medium bodied presenting flavors of pomegranate and sour cherry with a slightly tart finish
offers mild berry fruit allied to some green bell pepper and herb aromas. a bit light and tart fo a single vineyrd wine, but still good.	offers mild berry fruit allied to some green bell pepper and herb aromas a bit light and tart fo a single vineyrd wine but still good
pressed blueberry, black pepper and pencil lead show on this nose of this 50% grenache and 50% syrah blend by former football pro terry hoage, who recently renamed his brand. the palate on this juicy yet spicy bottling offers smoked meats and beef-jerky flavors with tar, black pepper and tangy boysenberry.	pressed blueberry black pepper and pencil lead show on this nose of this 50 grenache and 50 syrah blend by former football pro terry hoage who recently renamed his brand the palate on this juicy yet spicy bottling offers smoked meats and beefjerky flavors with tar black pepper and tangy boysenberry
this plush, full-bodied wine is already delicious, delivering wave after wave of savory fruit flavor, something like soy-marinated, char-grilled beef. tannins are supple enough to make this wine drinkable now, yet plentiful enough to suggest ample cellaring potential. drink now-2030.	this plush fullbodied wine is already delicious delivering wave after wave of savory fruit flavor something like soymarinated chargrilled beef tannins are supple enough to make this wine drinkable now yet plentiful enough to suggest ample cellaring potential drink now2030

Tahap berikutnya adalah penghapusan angka (remove number). Angka yang terdapat dalam teks dihilangkan karena umumnya tidak relevan dalam analisis deskripsi wine. Perubahan hasil preprocessing pada tahap ini dapat dilihat pada Tabel

Before	After
dark and charred with aromas of shoe polish asphalt coconut and blackberry its masculine in style with firm tannins that bite down in support of concentrated black fruit chocolate and spice flavors coffee bitterness and heat work the finish on this tannic fullbodied cabernet	dark and charred with aromas of shoe polish asphalt coconut and blackberry its masculine in style with firm tannins that bite down in support of concentrated black fruit chocolate and spice flavors coffee bitterness and heat work the finish on this tannic fullbodied cabernet
this is textbook central otago pinot from the nuances of wild thyme to the bold cherry fruit and mouthwatering finish this mediumbodied wine is structured enough to last several years but soft enough to drink now	this is textbook central otago pinot from the nuances of wild thyme to the bold cherry fruit and mouthwatering finish this mediumbodied wine is structured enough to last several years but soft enough to drink now
savory whiffs of dried herbs pine needles and dusty minerals open to a bright delicately fruity palate of crisp tangerine and quince dry and spry it offers brisk cooling refreshment drink now2017	savory whiffs of dried herbs pine needles and dusty minerals open to a bright delicately fruity palate of crisp tangerine and quince dry and spry it offers brisk cooling refreshment drink now
this is a creamy compelling bordelais style of sauvignon blanc candied lemon peel dried apple light honey and and petrol aromas show on the nose the rich palate offers poached pear sea salt and preserved lemon flavors presented on waves of soft plush texture	this is a creamy compelling bordelais style of sauvignon blanc candied lemon peel dried apple light honey and and petrol aromas show on the nose the rich palate offers poached pear sea salt and preserved lemon flavors presented on waves of soft plush texture
feels heavy and soft with ultraripe blackberry and cherry flavors that have a raisiny portlike quality the tannins are beautiful as they always are in pride wines and the finish is dry and complex could surprise but doesnt seem like an ager	feels heavy and soft with ultraripe blackberry and cherry flavors that have a raisiny portlike quality the tannins are beautiful as they always are in pride wines and the finish is dry and complex could surprise but doesnt seem like an ager

Setelah itu dilakukan pembersihan spasi berlebih (whitespace removal) untuk memastikan bahwa tidak terdapat spasi ganda atau karakter kosong yang tidak diperlukan. Proses ini bertujuan untuk merapikan struktur teks sehingga lebih konsisten.

Kemudian dilakukan stopword removal, yaitu proses menghapus kata-kata umum seperti “the”, “is”, dan “and” yang tidak memiliki makna signifikan dalam analisis.

Dengan menghilangkan stopwords, informasi yang tersisa menjadi lebih relevan. Hasil proses ini dapat dilihat pada Tabel

Before	After
m stands for monumental and at this is definitely a powered wine the pichlers wait to get the ripest healthy grapes and the result is a big opulent wine with pineapple and mango flavors some acidity remains in all this rococo extravaganza	stands monumental definitely powered wine pichlers wait get ripest healthy grapes result big opulent wine pineapple mango flavors acidity remains rococo extravaganza
the gold capsule oldfield series wines occupy a sort of reserve tier this is principally a blend of chardonnay sémillon and sauvignon blanc with a splash of viognier and muscat adding aromatic highlights snappy citrus fruit and a light dusting of cinnamon makes this wellcrafted wine a versatile refreshing option for a variety of seafood and salad entrées	gold capsule oldfield series wines occupy sort reserve tier principally blend chardonnay sémillon sauvignon blanc splash viognier muscat adding aromatic highlights snappy citrus fruit light dusting cinnamon makes wellcrafted wine versatile refreshing option variety seafood salad entrées
pécharmant produces some of the most dense reds of bergerac and this wine from ancienne cure shows some of the same character in a more fruity version black fruits and firm tannins are layered with forward acidity to give a wine that will be approachable this year	pécharmant produces dense reds bergerac wine ancienne cure shows character fruity version black fruits firm tannins layered forward acidity give wine approachable year
the chalk soil of champagne makes a reappearance in the pfersigberg vineyard in this wine it shows as elegance and crispness thats not to take away from the rich rounded texture and exotic fruits it adds complexity and great style drink from	chalk soil champagne makes reappearance pfersigberg vineyard wine shows elegance crispness thats take away rich rounded texture exotic fruits adds complexity great style drink
nearly all varietal with just a splash of syrah added it has notes of sweet spices cocoa and cherry backed by dry chalky tannins a pleasant easy drinker	nearly varietal splash syrah added notes sweet spices cocoa cherry backed dry chalky tannins pleasant easy drinker

Tahap berikutnya adalah lemmatization, yaitu proses mengubah kata ke bentuk dasar (lemma) berdasarkan aturan linguistik dan kamus bahasa. Lemmatization dilakukan untuk mengurangi variasi kata sehingga kata-kata yang memiliki makna sama dapat direpresentasikan dalam bentuk yang lebih seragam tanpa menghilangkan makna aslinya.

Pada penelitian ini digunakan WordNet Lemmatizer dari pustaka NLTK. Berbeda dengan stemming yang hanya memotong imbuhan secara mekanis, lemmatization mempertimbangkan struktur bahasa sehingga menghasilkan bentuk kata dasar yang lebih valid secara linguistik. Sebagai contoh, kata "aromas" diubah menjadi "aroma", "years" menjadi "year", dan "combines" menjadi "combine".

Melalui proses ini, jumlah variasi kata dalam dataset dapat dikurangi sehingga representasi teks menjadi lebih konsisten dan mampu meningkatkan kualitas fitur yang digunakan dalam proses klasifikasi. Hasil lemmatization ditampilkan pada Tabel.


Before	After
one several châteaux saintestèphe come plateau pez lightly structured wine alreadyforward black currant fruitiness acidity developing quickly ready drink	one sever châteaux saintestèph come plateau pez lightli structur wine alreadyforward black currant fruiti acid develop quickli readi drink
full bouquet includes aromas licorice tire rubber dried cheese ripe plum berry fruits flush pulpy fruity mouth cab franc shows bold boysenberry currant plum spice tea flavors finish smooth good flow moderate tannins drink	full bouquet includ aroma licoric tire rubber dri chees ripe plum berri fruit flush pulpi fruiti mouth cab franc show bold boysenberri currant plum spice tea flavor finish smooth good flow moder tannin drink
underbrush blackberry blue flower mocha lead nose blend sangiovese cabernet sauvignon syrah dense palate offers cassis black cherry black pepper espresso licorice alongside youthfully assertive tannins drink	underbrush blackberri blue flower mocha lead nose blend sangioves cabernet sauvignon syrah dens palat offer cassi black cherri black pepper espresso licoric alongsid youth assert tannin drink
shy nose suggestions cassis smoky oak flavors veer toward berries spices swimming firm tannins sharp acidity delicate wine one finesse rather power good long sweetly ripe finish suggests ageability probably youthful fleshy best	shi nose suggest cassi smoki oak flavor veer toward berri spice swim firm tannin sharp acid delic wine one finess rather power good long sweetli ripe finish suggest ageabl probabl youth fleshi best
fivegrape bordeaux blend dominated merlot cab franc deft mix grapes nicely melded complete satisfying wine anchored black cherry cassis fruit supple focused surrounding core fruit layers smoke black olive pencil lead coffee grounds resonates gracefully long finish	fivegrap bordeaux blend domin merlot cab franc deft mix grape nice meld complet satisfi wine anchor black cherri cassi fruit suppl focus surround core fruit layer smoke black oliv pencil lead coffe ground reson grace long finish

Sebagai tahap akhir, seluruh hasil preprocessing digabungkan kembali menjadi teks yang bersih dan siap digunakan dalam proses analisis lebih lanjut. Teks akhir ini merupakan hasil dari seluruh tahapan preprocessing yang telah dilakukan. Perbandingan antara teks sebelum dan sesudah preprocessing dapat dilihat pada Tabel.

Before	After
Soft, tangy and fruity, this is a ripe wine that shows both freshness and richness. It's approachable now,	soft tangi fruiti ripe wine show fresh rich approach full cream appl flavor delici drink apéritif screwcap

and full of creamed apple flavor. Delicious to drink as an apéritif. Screwcap.	
Sweet aromas of wet clay and latex give way to spicecake and standard berry and cassis. Feels layered and round, with good density and balance to go with berry, cassis and mild herbal flavors. Holds steady on the finish. A regular but solid Cab for everyday purposes.	sweet aroma wet clay latex give way spicecak standard berri cassi feel layer round good densiti balanc go berri cassi mild herbal flavor hold steadi finish regular solid cab everyday purpos
Big aromas of blackberry and raspberry feed into a full, fresh and ultimately standard palate with grapy blackberry flavors that show a controlled herbal side. Toasty and a touch bitter on the finish, it has a minty aftertaste.	big aroma blackberri raspberri feed full fresh ultim standard palat grapi blackberri flavor show control herbal side toasti touch bitter finish minti aftertast
Red-berry aromas are damp, mulchy and not fully fresh. On the palate, this wine feels sticky, while flavors of briny, herbal red-berry fruits turn salty on the finish.	redberri aroma damp mulchi fulli fresh palat wine feel sticki flavor brini herbal redberri fruit turn salti finish
This beautifully bold and opulent Barolo opens with dark extraction and super-soft aromas of melted milk chocolate, red cherry, vanilla cream, cinnamon and dark spice. The mouthfeel is rich and soft with sweet cherry flavors on the close.	beauti bold opul barolo open dark extract supersoft aroma melt milk chocol red cherri vanilla cream cinnamon dark spice mouthfeel rich soft sweet cherri flavor close

Analisis Distribusi Panjang Teks (Sebelum & Sesudah Cleaning)



Gambar. Analisis Distribusi Panjang Teks (Sebelum & Sesudah Cleaning)

Representasi Teks (Feature Representation)

TF-IDF


Setelah proses preprocessing selesai dilakukan, tahap berikutnya adalah transformasi data teks menjadi bentuk numerik. Tahap ini diperlukan karena algoritma machine learning tidak dapat memproses data dalam bentuk teks secara langsung, sehingga diperlukan representasi numerik yang dapat diolah lebih lanjut. Pada penelitian ini, metode yang digunakan untuk transformasi data adalah TF-IDF (Term Frequency–Inverse Document Frequency). Metode ini bekerja dengan memberikan bobot pada setiap kata berdasarkan dua hal, yaitu frekuensi kemunculan kata dalam suatu dokumen (term frequency) dan tingkat keunikan kata tersebut dalam keseluruhan dokumen (inverse document frequency). Dengan demikian, kata yang sering muncul dalam satu dokumen tetapi jarang muncul di dokumen lain akan memiliki nilai yang lebih tinggi, sehingga dianggap lebih penting.

Proses transformasi dilakukan pada kolom `final_text` yang merupakan hasil akhir dari tahap preprocessing. Setiap dokumen kemudian diubah menjadi vektor numerik dengan jumlah fitur tertentu. Pada penelitian ini digunakan batasan jumlah fitur sebanyak 5000 kata, sehingga setiap dokumen direpresentasikan dalam bentuk vektor berdimensi 5000. Hasil dari proses transformasi ini menghasilkan matriks TF-IDF dengan ukuran (jumlah data $\times$ jumlah fitur). Sebagian besar nilai dalam matriks ini bernilai nol, karena tidak semua kata muncul dalam setiap dokumen. Hal ini merupakan karakteristik umum dari representasi TF-IDF yang bersifat sparse matrix.

Untuk mempermudah visualisasi, hanya sebagian kecil data dan fitur yang ditampilkan dalam bentuk tabel. Tabel berikut menunjukkan contoh hasil transformasi teks menjadi representasi numerik menggunakan metode TF-IDF

Tabel TF-IDF

Fitur (Unigram)	Dokumen 0	Dokumen 1	Dokumen 2	Dokumen 3	Dokumen 4
abbey	0.0	0.0	0.0	0.0	0.0
abbreviated	0.0	0.0	0.0	0.0	0.0
ability	0.0	0.0	0.0	0.0	0.0
able	0.0	0.0	0.0	0.0	0.0
abound	0.0	0.0	0.0	0.0	0.0
abounds	0.0	0.0	0.0	0.0	0.0
abrasive	0.0	0.0	0.0	0.0	0.0
abrupt	0.0	0.0	0.0	0.0	0.0
abruptly	0.0	0.0	0.0	0.0	0.0
absolute	0.0	0.0	0.0	0.0	0.0



Setelah dilakukan transformasi, setiap dokumen kini direpresentasikan dalam bentuk angka yang menunjukkan tingkat kepentingan kata dalam dokumen tersebut. Nilai 0 menunjukkan bahwa kata tidak muncul dalam dokumen, sedangkan nilai selain 0 menunjukkan kontribusi kata tersebut terhadap dokumen. Representasi ini selanjutnya akan digunakan sebagai input dalam proses pemodelan klasifikasi.

N-Gram

Setelah dilakukan transformasi menggunakan metode TF-IDF, pada tahap ini dilakukan representasi teks menggunakan metode N-Gram. Metode ini merupakan teknik dalam Natural Language Processing (NLP) yang digunakan untuk membentuk fitur berdasarkan kombinasi kata yang muncul secara berurutan dalam suatu teks. Pada penelitian ini digunakan bigram (2-gram), yaitu kombinasi dua kata yang berurutan. Pemilihan bigram dilakukan untuk menangkap konteks antar kata yang tidak dapat direpresentasikan oleh unigram (satu kata). Dengan demikian, model tidak hanya melihat kata secara terpisah, tetapi juga memperhatikan hubungan antar kata dalam teks.

Proses transformasi dilakukan menggunakan metode CountVectorizer, di mana setiap dokumen diubah menjadi representasi numerik berdasarkan frekuensi kemunculan setiap bigram. Seluruh pasangan kata berurutan dari setiap dokumen akan dikumpulkan, kemudian dihitung jumlah kemunculannya dalam dataset. Selanjutnya, dari seluruh pasangan kata tersebut dipilih sejumlah fitur berdasarkan kemunculannya dalam data. Dengan demikian, kata-kata atau pasangan kata yang digunakan dalam tabel bukan dipilih secara acak, melainkan merupakan hasil dari proses perhitungan pada seluruh dokumen.



Fitur yang digunakan merepresentasikan pola kata yang terdapat dalam dataset. Berbeda dengan TF-IDF yang menghasilkan bobot, metode N-Gram menghasilkan nilai berupa jumlah kemunculan pasangan kata dalam setiap dokumen. Hasil transformasi ini berupa matriks dengan ukuran (jumlah data $\times$ jumlah fitur), di mana setiap kolom

merepresentasikan satu fitur bigram. Sebagian besar nilai dalam matriks bernilai nol karena tidak semua pasangan kata muncul pada setiap dokumen. Hal ini merupakan karakteristik umum dari representasi teks berbasis frekuensi yang bersifat sparse.

Pada tabel yang ditampilkan, terlihat bahwa sebagian besar nilai bernilai 0. Hal ini menunjukkan bahwa pasangan kata yang digunakan sebagai fitur tidak muncul pada dokumen yang ditampilkan. Nilai 1 menunjukkan bahwa pasangan kata muncul dalam dokumen, sedangkan nilai 0 menunjukkan bahwa pasangan kata tidak muncul dalam dokumen tersebut. Untuk mempermudah visualisasi, hanya sebagian kecil data dan fitur yang ditampilkan dalam bentuk tabel.

Tabel N-Gram

Fitur Bigram	Dokumen 0	Dokumen 1	Dokumen 2	Dokumen 3	Dokumen 4
berry fruit	0	0	0	0	0
black cherry	0	0	0	0	0
black currant	0	0	0	0	0
black fruit	0	0	0	0	0
black pepper	0	0	0	0	0
cabernet sauvignon	0	0	0	0	0
crisp acidity	0	0	0	0	0
finish drink	0	0	0	0	0
firm tannin	0	0	0	0	0
flavor finish	0	0	0	0	0
fruit flavor	0	0	0	0	0
palate offer	0	0	0	0	0
pinot noir	0	0	0	0	0
ready drink	0	0	0	0	0
red berry	0	0	0	0	0
red cherry	0	0	0	0	0
red fruit	0	0	0	0	0
stone fruit	0	0	1	0	0
tropical fruit	0	0	0	0	0
white pepper	0	0	0	0	0



Bag of Words

Setelah dilakukan transformasi menggunakan metode N-Gram, pada tahap ini dilakukan representasi teks menggunakan metode Bag of Words (BOW). Metode ini merupakan teknik dalam Natural Language Processing (NLP) yang digunakan untuk mengubah teks menjadi representasi numerik berdasarkan kata-kata yang muncul dalam dokumen, tanpa memperhatikan urutan kata.

Pada metode Bag of Words, setiap dokumen direpresentasikan sebagai kumpulan kata (bag) yang disusun berdasarkan frekuensi kemunculannya. Berbeda dengan N-Gram yang mempertimbangkan urutan kata, BOW hanya memperhatikan keberadaan dan jumlah kemunculan kata dalam teks.

Proses transformasi dilakukan menggunakan metode CountVectorizer, di mana seluruh teks diubah menjadi sekumpulan kata unik (vocabulary). Setiap kata yang muncul dalam dataset akan menjadi fitur, kemudian dihitung frekuensi kemunculannya dalam setiap dokumen.

Selanjutnya, dilakukan pemilihan fitur dengan mengambil kata-kata yang memiliki frekuensi kemunculan tertinggi dalam seluruh dataset. Dengan demikian, fitur yang digunakan dalam tabel merupakan kata-kata yang paling sering muncul dan dianggap paling representatif dalam menggambarkan isi data.


Hasil transformasi ini berupa matriks dengan ukuran (jumlah data $\times$ jumlah fitur), di mana setiap kolom merepresentasikan satu kata, dan setiap baris merepresentasikan satu dokumen. Nilai pada tabel menunjukkan jumlah kemunculan kata dalam dokumen tersebut. Nilai 0 menunjukkan bahwa kata tidak muncul dalam dokumen, sedangkan nilai lebih dari 0 menunjukkan jumlah kemunculan kata dalam dokumen.

Berdasarkan hasil yang diperoleh, terlihat bahwa beberapa kata memiliki nilai lebih dari 0 pada dokumen tertentu. Hal ini menunjukkan bahwa kata tersebut muncul dalam dokumen tersebut. Sementara itu, nilai 0 menunjukkan bahwa kata tidak ditemukan dalam dokumen. Untuk mempermudah visualisasi, hanya sebagian kecil data dan fitur yang ditampilkan dalam bentuk tabel.

Tabel BoW

Fitur (BoW)	Dokumen 0	Dokumen 1	Dokumen 2	Dokumen 3	Dokumen 4
acidity	0	1	0	0	0
aroma	0	0	1	0	0
cherry	0	0	0	1	1
drink	0	0	0	1	0
finish	0	0	1	0	0
flavor	1	1	1	2	1
fruit	0	0	1	0	1

palate	0	0	0	0	0
tannin	0	0	0	0	0
wine	0	2	0	1	1



Dalam penelitian ini digunakan beberapa pendekatan representasi teks, yaitu Bag of Words (BoW), TF-IDF, N-Gram, Word2Vec, GloVe, dan BERT. Representasi tersebut digunakan untuk mengubah data teks menjadi bentuk numerik yang dapat diproses oleh algoritma machine learning.

Selanjutnya dilakukan pengujian menggunakan dua algoritma klasifikasi, yaitu Decision Tree (DT) dan Naive Bayes (NB). Decision Tree merupakan algoritma berbasis struktur pohon keputusan yang mampu menghasilkan model yang mudah diinterpretasikan, sedangkan Naive Bayes merupakan algoritma probabilistik yang banyak digunakan pada klasifikasi teks karena sederhana, efisien, dan memiliki performa yang baik pada data berdimensi tinggi.

Setiap kombinasi metode representasi teks dan algoritma klasifikasi akan dievaluasi menggunakan metrik Accuracy, Precision, Recall, dan F1-Score. Selain itu, digunakan juga Confusion Matrix untuk menganalisis performa model dalam mengklasifikasikan masing-masing kategori kualitas wine. Hasil dari setiap eksperimen kemudian dibandingkan untuk mengetahui kombinasi metode yang memberikan performa terbaik pada proses klasifikasi kualitas wine.

Eksperimen 1: Naive Bayes + Bag of Words (BoW)

Pada eksperimen pertama, dilakukan klasifikasi kualitas wine menggunakan algoritma Naive Bayes (NB) dengan representasi fitur Bag of Words (BoW). Metode Bag of Words digunakan untuk mengubah data teks hasil preprocessing menjadi representasi numerik berdasarkan frekuensi kemunculan kata pada setiap dokumen.

Algoritma Naive Bayes dipilih karena memiliki performa yang baik pada data teks berdimensi tinggi serta mampu melakukan proses klasifikasi dengan cepat. Naive Bayes bekerja berdasarkan Teorema Bayes dengan asumsi bahwa setiap fitur bersifat independen

satu sama lain. Meskipun asumsi tersebut cukup sederhana, algoritma ini banyak digunakan dalam klasifikasi teks karena efisien dan memiliki kompleksitas komputasi yang rendah.

Pada penelitian ini digunakan representasi Bag of Words dengan jumlah fitur sebanyak 2000 kata yang paling sering muncul pada dataset. Hasil transformasi menghasilkan matriks fitur dengan ukuran (7952×2000) . Setiap dokumen direpresentasikan sebagai vektor frekuensi kata yang kemudian digunakan sebagai masukan bagi model Naive Bayes untuk melakukan klasifikasi kualitas wine ke dalam kategori Low, Medium, dan High

Berdasarkan hasil transformasi Bag of Words (BoW), setiap dokumen direpresentasikan dalam bentuk vektor numerik berdasarkan frekuensi kemunculan kata. Setiap kolom merepresentasikan satu kata (fitur), sedangkan setiap baris merepresentasikan satu dokumen. Nilai 0 menunjukkan bahwa kata tidak muncul pada dokumen tersebut, sedangkan nilai lebih dari 0 menunjukkan jumlah kemunculan kata dalam dokumen. Pada tabel terlihat bahwa sebagian besar nilai bernilai 0 karena tidak semua kata muncul pada setiap dokumen. Kondisi ini merupakan karakteristik umum representasi Bag of Words yang menghasilkan matriks sparse dengan jumlah fitur yang cukup besar. Representasi numerik ini selanjutnya digunakan sebagai input dalam proses klasifikasi menggunakan algoritma Naive Bayes.

Hasil Evaluasi

Model	Accuracy	Precision	Recall	F1-Score	Error Rate
NB + BoW	0.632479	0.640608	0.632479	0.634411	0.367521


Berdasarkan hasil evaluasi, model Naive Bayes dengan representasi Bag of Words memperoleh nilai accuracy sebesar 63,24%. Nilai precision sebesar 64,06%, recall sebesar 63,24%, dan F1-score sebesar 63,44% menunjukkan bahwa model mampu melakukan klasifikasi dengan performa yang cukup baik pada data review win.

Classification Report

Kelas	Precision (%)	Recall (%)	F1-Score (%)	Support
High	56.00	66.00	60.00	526
Low	55.00	58.00	57.00	337
Medium	70.00	63.00	67.00	1126
Accuracy	-	-	63.00	1989
Macro Average	61.00	63.00	61.00	1989
Weighted Average	64.00	63.00	63.00	1989

Berdasarkan hasil evaluasi model, diperoleh nilai akurasi sebesar 63%. Kelas Medium memiliki performa terbaik dengan nilai precision sebesar 70%, recall sebesar 63%, dan

F1-score sebesar 67%. Sementara itu, kelas High memperoleh F1-score sebesar 60% dan kelas Low sebesar 57%. Nilai weighted average F1-score sebesar 63% menunjukkan bahwa model memiliki kemampuan klasifikasi yang cukup baik dalam membedakan kategori kualitas wine berdasarkan teks ulasan.



Berdasarkan confusion matrix, model berhasil mengklasifikasikan 346 data kelas High, 197 data kelas Low, dan 715 data kelas Medium dengan benar. Kelas Medium merupakan kelas yang paling banyak diprediksi dengan benar karena jumlah datanya lebih dominan dibandingkan kelas lainnya.

Namun masih terdapat beberapa kesalahan klasifikasi. Sebanyak 260 data Medium diprediksi sebagai High dan 151 data Medium diprediksi sebagai Low. Selain itu, terdapat 128 data Low yang diprediksi sebagai Medium serta 172 data High yang diprediksi sebagai Medium. Hal ini menunjukkan bahwa karakteristik teks pada ketiga kategori kualitas wine masih memiliki kemiripan sehingga model kesulitan membedakannya secara sempurna.

Interpretasi Model

Model Naive Bayes dengan representasi Bag of Words mampu mengklasifikasikan kualitas wine dengan cukup baik berdasarkan frekuensi kemunculan kata pada teks review. Model menunjukkan performa terbaik pada kelas Medium karena jumlah datanya lebih

dominan dibandingkan kelas lainnya. Namun, masih terdapat kesalahan klasifikasi antara kelas High, Medium, dan Low karena metode Bag of Words hanya mempertimbangkan frekuensi kata tanpa memperhatikan konteks maupun hubungan antar kata. Meskipun demikian, hasil yang diperoleh menunjukkan bahwa kombinasi Naive Bayes dan Bag of Words cukup efektif sebagai model dasar (baseline) untuk klasifikasi teks review wine.

Eksperimen 2: Naive Bayes + TF-IDF

Pada eksperimen kelima, dilakukan klasifikasi kualitas wine menggunakan algoritma Naive Bayes (NB) dengan representasi fitur Term Frequency-Inverse Document Frequency (TF-IDF). Metode TF-IDF digunakan untuk mengubah data teks hasil preprocessing menjadi representasi numerik dengan memberikan bobot pada setiap kata berdasarkan tingkat kepentingannya dalam dokumen.

Berbeda dengan Bag of Words yang hanya menghitung frekuensi kemunculan kata, TF-IDF mempertimbangkan frekuensi kata dalam suatu dokumen serta tingkat kemunculan kata tersebut pada seluruh dokumen. Dengan demikian, kata-kata yang sering muncul pada satu dokumen tetapi jarang muncul pada dokumen lain akan memperoleh bobot yang lebih tinggi.

Pada penelitian ini digunakan representasi TF-IDF dengan jumlah fitur sebanyak 2000 kata. Hasil transformasi menghasilkan matriks fitur berukuran (7952×2000) yang selanjutnya digunakan sebagai masukan bagi algoritma Naive Bayes untuk melakukan klasifikasi kualitas wine ke dalam kategori Low, Medium, dan High.

Berdasarkan hasil transformasi TF-IDF, setiap dokumen direpresentasikan dalam bentuk vektor numerik berdasarkan tingkat kepentingan kata dalam dokumen. Nilai yang lebih tinggi menunjukkan bahwa kata tersebut memiliki kontribusi yang lebih besar terhadap dokumen tertentu. Berbeda dengan Bag of Words yang hanya menghitung frekuensi kata, TF-IDF mampu mengurangi pengaruh kata-kata yang terlalu sering muncul pada seluruh dokumen sehingga menghasilkan representasi fitur yang lebih informatif

Hasil Evaluasi


Model	Accuracy	Error Rate	Precision	Recall	F1-Score
NB + TF-IDF	0.635495	0.364505	0.642487	0.635495	0.637196

Classification Report

Kelas	Precision (%)	Recall (%)	F1-Score (%)	Support
High	57.00	66.00	61.00	526
Low	55.00	56.00	56.00	337

Medium	71.00	64.00	67.00	1126
Accuracy	-	-	64.00	1989
Macro Average	61.00	62.00	61.00	1989
Weighted Average	64.00	64.00	64.00	1989

Berdasarkan hasil evaluasi, model Naive Bayes dengan representasi TF-IDF memperoleh nilai accuracy sebesar 63,55%. Nilai precision sebesar 64,25%, recall sebesar 63,55%, dan F1-score sebesar 63,72% menunjukkan bahwa model mampu melakukan klasifikasi kualitas wine dengan cukup baik. Dibandingkan dengan representasi Bag of Words, metode TF-IDF memberikan peningkatan performa meskipun tidak terlalu signifikan. Hal ini menunjukkan bahwa pemberian bobot berdasarkan tingkat kepentingan kata mampu membantu model dalam mengenali informasi yang lebih relevan pada dokumen.



Berdasarkan confusion matrix, model berhasil mengklasifikasikan 348 data kelas High, 190 data kelas Low, dan 726 data kelas Medium dengan benar. Kelas Medium memiliki jumlah prediksi benar paling tinggi dibandingkan kelas lainnya karena merupakan kelas dengan jumlah data terbesar dalam dataset.

Namun, masih terdapat beberapa kesalahan klasifikasi. Sebanyak 169 data kelas High diprediksi sebagai Medium dan 9 data kelas High diprediksi sebagai Low. Pada kelas Low, terdapat 133 data yang diprediksi sebagai Medium dan 14 data diprediksi sebagai High. Sementara itu, pada kelas Medium terdapat 253 data yang diprediksi sebagai High dan 147 data yang diprediksi sebagai Low. Kesalahan klasifikasi ini menunjukkan bahwa karakteristik teks pada ketiga kategori kualitas wine masih memiliki kemiripan sehingga model belum mampu membedakan seluruh kelas secara sempurna.

Interpretasi Model

Kombinasi Naive Bayes dan TF-IDF mampu menghasilkan performa yang cukup baik dalam klasifikasi kualitas wine. Pemberian bobot TF-IDF membantu model lebih fokus pada kata-kata yang memiliki nilai informasi tinggi sehingga meningkatkan kemampuan model dalam mengenali pola pada data teks. Namun, model masih menunjukkan kecenderungan memprediksi kelas Medium lebih sering dibandingkan kelas lainnya akibat distribusi data yang tidak seimbang.

Eksperimen 3: Naive Bayes + N-Gram (Bigram)

Pada eksperimen keenam, dilakukan klasifikasi kualitas wine menggunakan algoritma Naive Bayes (NB) dengan representasi fitur N-Gram (Bigram). Metode N-Gram digunakan untuk merepresentasikan teks berdasarkan kombinasi dua kata yang muncul secara berurutan dalam dokumen. Dengan menggunakan Bigram, model tidak hanya memperhatikan kemunculan kata secara individual, tetapi juga hubungan antar kata yang muncul secara berdekatan.

Representasi Bigram memungkinkan model menangkap informasi konteks yang tidak dapat diperoleh dari metode Bag of Words. Setiap pasangan kata direpresentasikan sebagai fitur numerik yang kemudian digunakan sebagai masukan bagi algoritma Naive Bayes untuk melakukan klasifikasi kualitas wine ke dalam kategori Low, Medium, dan High.

Berdasarkan hasil transformasi N-Gram (Bigram), setiap fitur merepresentasikan pasangan dua kata yang muncul secara berurutan dalam dokumen. Nilai 0 menunjukkan bahwa pasangan kata tersebut tidak muncul pada dokumen, sedangkan nilai 1 menunjukkan keberadaan pasangan kata tersebut. Representasi ini memungkinkan model memanfaatkan hubungan antar kata sehingga dapat menangkap konteks yang lebih baik dibandingkan metode Bag of Words.


Hasil Evaluasi

Model	Accuracy	Error Rate	Precision	Recall	F1-score
NB + N-Gram	0.500754	0.499246	0.528471	0.500754	0.507119

Classification Report

Kelas	Precision (%)	Recall (%)	F1-Score (%)	Support
High	40.00	56.00	47.00	526
Low	36.00	39.00	38.00	337
Medium	64.00	51.00	57.00	1126
Accuracy	-	-	50.00	1989
Macro Average	47.00	48.00	47.00	1989
Weighted Average	53.00	50.00	51.00	1989

Berdasarkan hasil evaluasi, model Naive Bayes dengan representasi N-Gram (Bigram) memperoleh nilai accuracy sebesar 50,08%, precision sebesar 52,85%, recall sebesar 50,08%, dan F1-score sebesar 50,71%. Hasil ini menunjukkan bahwa performa model masih berada di bawah metode Bag of Words maupun TF-IDF.



Berdasarkan confusion matrix, model berhasil mengklasifikasikan 292 data kelas High, 132 data kelas Low, dan 572 data kelas Medium dengan benar. Kelas Medium memiliki jumlah prediksi benar tertinggi dibandingkan kelas lainnya.

Namun, masih terdapat cukup banyak kesalahan klasifikasi. Sebanyak 195 data kelas High diprediksi sebagai Medium dan 39 data kelas High diprediksi sebagai Low. Pada kelas Low, terdapat 130 data yang diprediksi sebagai Medium dan 75 data diprediksi sebagai High. Sementara itu, pada kelas Medium terdapat 359 data yang diprediksi sebagai High dan 195 data yang diprediksi sebagai Low. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas berdasarkan representasi Bigram yang digunakan.

Interpretasi Model

Kombinasi Naive Bayes dan N-Gram (Bigram) mampu menangkap hubungan antar kata melalui pasangan kata yang muncul secara berurutan. Namun, berdasarkan hasil evaluasi yang memperoleh accuracy sebesar 50,08% dan weighted F1-score sebesar 51%, performa model masih lebih rendah dibandingkan penggunaan Bag of Words maupun TF-IDF. Hal ini menunjukkan bahwa fitur Bigram yang digunakan belum mampu memberikan informasi

yang cukup kuat untuk membedakan kualitas wine secara optimal. Selain itu, distribusi data yang tidak seimbang menyebabkan model masih cenderung mengalami kesalahan klasifikasi, terutama pada kelas Medium yang sering tertukar dengan kelas High dan Low.

Eksperimen 4: Decision Tree + Bag of Words (BoW)

Pada eksperimen pertama, digunakan metode Bag of Words (BoW) untuk merepresentasikan teks menjadi bentuk numerik. Metode ini mengubah setiap dokumen menjadi vektor berdasarkan frekuensi kemunculan kata tanpa mempertimbangkan urutan kata. Hasil transformasi ini kemudian digunakan sebagai input untuk model Decision Tree dalam proses klasifikasi kualitas wine.


Hasil Evaluasi

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + BoW	0.482655	0.517345	0.513626	0.482655	0.488933

Classification Report

Kelas	Precision (%)	Recall (%)	F1-Score (%)	Support
High	43.00	43.00	43.00	526
Low	34.00	58.00	43.00	337
Medium	61.00	48.00	54.00	1126
Accuracy	-	-	48.00	1989
Macro Average	46.00	49.00	46.00	1989
Weighted Average	51.00	48.00	49.00	1989

Berdasarkan hasil pengujian, model Decision Tree dengan representasi Bag of Words (BoW) memperoleh nilai accuracy sebesar 48,27%, precision sebesar 51,36%, recall sebesar 48,27%, dan F1-score sebesar 48,89%. Hasil tersebut menunjukkan bahwa model masih memiliki kemampuan klasifikasi yang relatif rendah dalam membedakan kategori kualitas wine berdasarkan teks ulasan.



Berdasarkan confusion matrix, model berhasil mengklasifikasikan 226 data kelas High, 194 data kelas Low, dan 540 data kelas Medium dengan benar. Kelas Medium memiliki jumlah prediksi benar paling banyak dibandingkan kelas lainnya.

Namun, masih terdapat cukup banyak kesalahan klasifikasi. Sebanyak 233 data kelas High diprediksi sebagai Medium dan 67 data kelas High diprediksi sebagai Low. Pada kelas Low, terdapat 118 data yang diprediksi sebagai Medium dan 25 data yang diprediksi sebagai High. Sementara itu, pada kelas Medium, terdapat 280 data yang diprediksi sebagai High dan 306 data yang diprediksi sebagai Low. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas kualitas wine sehingga menyebabkan tingkat kesalahan klasifikasi yang cukup tinggi.

Interpretasi Model

Model Decision Tree dengan representasi Bag of Words (BoW) masih memiliki keterbatasan dalam mengklasifikasikan kualitas wine berdasarkan teks review. Meskipun model mampu mengenali sebagian data pada setiap kelas, performa yang dihasilkan masih tergolong rendah dengan nilai akurasi sebesar 48,27%. Kelas Medium memiliki nilai precision tertinggi, yaitu 61%, sedangkan kelas Low memiliki nilai recall tertinggi, yaitu 58%. Hal ini menunjukkan bahwa model relatif lebih baik dalam mengenali data kelas Low, tetapi masih sering melakukan kesalahan dalam membedakan kelas High dan Medium.

Keterbatasan tersebut dapat disebabkan oleh representasi Bag of Words yang hanya memperhatikan frekuensi kemunculan kata tanpa mempertimbangkan konteks maupun hubungan antar kata. Selain itu, distribusi jumlah data yang tidak seimbang, di mana kelas Medium memiliki jumlah data yang jauh lebih banyak dibandingkan kelas lainnya, turut memengaruhi kemampuan model dalam membedakan kategori kualitas wine secara optimal.

Eksperimen 5: Decision Tree + TF-IDF

Pada eksperimen ketiga, digunakan metode TF-IDF (Term Frequency–Inverse Document Frequency) untuk merepresentasikan teks menjadi bentuk numerik. Metode ini memberikan bobot pada setiap kata berdasarkan frekuensi kemunculannya dalam suatu dokumen serta tingkat keunikannya dalam keseluruhan dataset.

Berbeda dengan metode representasi teks sebelumnya seperti Bag of Words (BoW) dan N-Gram, metode TF-IDF mampu memberikan bobot pada setiap kata berdasarkan tingkat kepentingannya dalam dokumen. Dengan demikian, TF-IDF tidak hanya mempertimbangkan frekuensi kemunculan kata, tetapi juga memperhatikan keunikan kata dalam keseluruhan dataset, sehingga menghasilkan representasi yang lebih informatif


Hasil Evaluasi

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + TF-IDF	0.536953	0.463047	0.547296	0.536953	0.540970

Classification Report

Kelas	Precision (%)	Recall (%)	F1-Score (%)	Support
High	48.00	49.00	48.00	526
Low	37.00	45.00	41.00	337
Medium	63.00	59.00	61.00	1126
Accuracy	-	-	54.00	1989
Macro Average	49.00	51.00	50.00	1989
Weighted Average	55.00	54.00	54.00	1989

Berdasarkan hasil pengujian model Decision Tree dengan representasi TF-IDF, diperoleh nilai accuracy sebesar 53,70%, error rate sebesar 46,30%, dan precision sebesar 54,73%. Nilai accuracy tersebut menunjukkan bahwa model mampu mengklasifikasikan data dengan tingkat ketepatan yang lebih baik dibandingkan model Decision Tree dengan representasi Bag of Words sebelumnya. Selain itu, nilai precision, recall, dan F1-score yang relatif seimbang menunjukkan bahwa model memiliki kemampuan yang cukup stabil dalam mengidentifikasi setiap kelas. Hal ini menunjukkan bahwa penggunaan TF-IDF mampu meningkatkan kualitas representasi teks sehingga model dapat menangkap informasi yang lebih relevan dari ulasan wine.



Berdasarkan confusion matrix yang dihasilkan, model berhasil mengklasifikasikan 257 data kelas High, 151 data kelas Low, dan 660 data kelas Medium dengan benar. Kelas Medium memiliki jumlah prediksi benar paling tinggi dibandingkan kelas lainnya, yang menunjukkan bahwa model lebih mampu mengenali pola pada kelas tersebut.

Namun, masih terdapat beberapa kesalahan klasifikasi pada setiap kelas. Pada kelas High, sebanyak 232 data diprediksi sebagai Medium dan 37 data diprediksi sebagai Low. Pada kelas Low, terdapat 150 data yang diprediksi sebagai Medium dan 36 data yang diprediksi sebagai High. Sementara itu, pada kelas Medium, sebanyak 247 data diprediksi sebagai High dan 219 data diprediksi sebagai Low. Kesalahan klasifikasi tersebut menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas yang memiliki pola teks yang serupa.

Interpretasi Model

Berdasarkan confusion matrix yang dihasilkan, model Decision Tree dengan representasi TF-IDF menunjukkan performa yang lebih baik dibandingkan model Decision Tree dengan Bag of Words. Model memiliki performa terbaik pada kelas Medium, dengan jumlah prediksi benar paling tinggi, yaitu sebanyak 660 data. Hal ini menunjukkan bahwa model lebih mudah mengenali pola pada kelas tersebut.

Meskipun demikian, masih terdapat kesalahan klasifikasi pada kelas High dan Low, di mana sejumlah data masih diprediksi ke kelas lain, terutama ke kelas Medium. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas yang memiliki pola teks yang mirip. Namun, secara keseluruhan penggunaan representasi TF-IDF memberikan peningkatan performa dibandingkan representasi Bag of

Words, karena TF-IDF mampu memberikan bobot yang lebih besar pada kata-kata yang lebih penting dan lebih representatif terhadap masing-masing kategori kualitas wine.

Eksperimen 6: Decision Tree + N-Gram (Bigram)

Pada eksperimen ini, digunakan metode N-Gram (Bigram) untuk merepresentasikan teks menjadi bentuk numerik. Berbeda dengan metode Bag of Words (BoW) yang hanya memperhatikan frekuensi kemunculan kata, metode N-Gram mempertimbangkan urutan kata dengan membentuk kombinasi dua kata yang muncul secara berurutan dalam teks.

Penggunaan bigram bertujuan untuk menangkap konteks antar kata yang tidak dapat direpresentasikan oleh unigram. Dengan demikian, model dapat memahami hubungan antar kata yang lebih kompleks dalam teks deskripsi wine.

Hasil transformasi menggunakan metode N-Gram kemudian digunakan sebagai input untuk model Decision Tree dalam proses klasifikasi kualitas wine.

Hasil Evaluasi

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + N-Gram	0.295123	0.704877	0.501786	0.295123	0.266233


Classification Report

Kelas	Precision (%)	Recall (%)	F1-Score (%)	Support
High	45.00	30.00	36.00	526
Low	21.00	87.00	33.00	337
Medium	61.00	12.00	20.00	1126
Accuracy	-	-	30.00	1989
Macro Average	42.00	43.00	30.00	1989
Weighted Average	50.00	30.00	27.00	1989

Berdasarkan hasil pengujian, model Decision Tree dengan representasi N-Gram (Bigram) memperoleh nilai accuracy sebesar 29,51%, precision sebesar 50,18%, recall sebesar 29,51%, dan F1-score sebesar 26,62%. Hasil tersebut menunjukkan bahwa performa model masih tergolong rendah dan belum mampu melakukan klasifikasi kualitas wine secara optimal.

Nilai precision yang relatif lebih tinggi dibandingkan recall menunjukkan bahwa prediksi yang dihasilkan model cukup tepat untuk beberapa kelas tertentu, namun model masih kesulitan dalam mengenali seluruh data pada masing-masing kelas. Rendahnya nilai F1-score juga menunjukkan bahwa keseimbangan antara precision dan recall masih kurang baik sehingga model belum memiliki konsistensi prediksi yang optimal.

Visualisasi



Berdasarkan confusion matrix yang dihasilkan, model berhasil mengklasifikasikan 156 data kelas High, 294 data kelas Low, dan 137 data kelas Medium dengan benar. Kelas Low memiliki jumlah prediksi benar paling tinggi dibandingkan kelas lainnya.

Namun, masih terdapat banyak kesalahan klasifikasi pada setiap kelas. Pada kelas High, sebanyak 308 data diprediksi sebagai Low dan 62 data diprediksi sebagai Medium. Pada kelas Low, terdapat 19 data yang diprediksi sebagai High dan 24 data yang diprediksi sebagai Medium. Sementara itu, pada kelas Medium, sebanyak 172 data diprediksi sebagai High dan 817 data diprediksi sebagai Low.

Jumlah kesalahan klasifikasi yang sangat besar pada kelas Medium menunjukkan bahwa model memiliki kecenderungan yang kuat untuk mengelompokkan data ke dalam kelas Low. Hal ini menyebabkan kemampuan model dalam mengenali kelas Medium menjadi sangat rendah.

Interpretasi Model

Berdasarkan hasil yang diperoleh, dapat disimpulkan bahwa penggunaan metode N-Gram (Bigram) mampu memberikan informasi tambahan berupa hubungan antar kata dibandingkan metode Bag of Words. Namun, performa model Decision Tree justru mengalami penurunan yang cukup signifikan, dengan nilai accuracy sebesar 29,51% dan F1-score sebesar 26,62%.

Berdasarkan confusion matrix, model menunjukkan performa terbaik pada kelas Low, dengan jumlah prediksi benar sebanyak 294 data dan nilai recall sebesar 87%. Sebaliknya, model memiliki performa yang sangat rendah pada kelas Medium, dengan hanya 137 data yang berhasil diklasifikasikan dengan benar dan nilai recall sebesar 12%. Hal ini menunjukkan

bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas yang memiliki pola teks yang mirip.

Selain itu, distribusi data yang tidak seimbang serta kompleksitas fitur hasil representasi bigram menyebabkan model Decision Tree belum mampu memanfaatkan informasi hubungan antar kata secara optimal. Akibatnya, model cenderung mengalami bias dalam memprediksi sebagian besar data kelas Medium ke dalam kelas Low, sehingga menghasilkan performa klasifikasi yang lebih rendah dibandingkan metode Bag of Words maupun TF-IDF.

Eksperimen 7: Decision Tree + Word2Vec (Self-Trained)

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Decision Tree (DT) dengan representasi fitur Word2Vec. Word2Vec digunakan untuk mengubah teks deskripsi wine menjadi vektor numerik sehingga informasi semantik antar kata dapat dipelajari oleh model. Selanjutnya, vektor hasil transformasi digunakan sebagai input dalam proses pelatihan dan pengujian model Decision Tree untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + Word2Vec	0.46908	0.53092	0.523184	0.46908	0.470962

Berdasarkan hasil evaluasi, model Decision Tree dengan representasi Word2Vec memperoleh accuracy sebesar 46,91% dengan error rate sebesar 53,09%. Nilai precision sebesar 52,32% menunjukkan bahwa prediksi model cukup tepat, sedangkan recall sebesar 46,91% mengindikasikan bahwa kemampuan model dalam mengenali seluruh kelas masih terbatas. Secara keseluruhan, nilai F1-score sebesar 47,10% menunjukkan bahwa performa model berada pada kategori sedang.


Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.42	0.63	0.51	526
Low	0.32	0.49	0.39	337
Medium	0.63	0.39	0.48	1126
Accuracy			0.47	1989
Macro Avg	0.46	0.50	0.46	1989
Weighted Avg	0.52	0.47	0.47	1989

Berdasarkan classification report, kelas High memiliki recall tertinggi sebesar 0,63, yang menunjukkan bahwa model cukup baik dalam mengenali wine berkualitas tinggi. Sebaliknya,

kelas Low memiliki performa terendah dengan F1-score sebesar 0,39, sedangkan kelas Medium memiliki precision tertinggi sebesar 0,63 namun recall yang relatif rendah.

Confusion Matrix



Berdasarkan confusion matrix, model berhasil mengklasifikasikan sebanyak 334 data High, 165 data Low, dan 434 data Medium dengan benar. Namun, masih terdapat kesalahan prediksi yang cukup besar, terutama pada kelas Medium yang sering diprediksi sebagai kelas lain. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas kualitas wine.

Interpretasi Model

Secara keseluruhan, kombinasi Decision Tree dan Word2Vec telah mampu memanfaatkan informasi semantik dari teks deskripsi wine untuk proses klasifikasi. Namun, dengan nilai accuracy sebesar 46,91%, performa model masih belum optimal sehingga dapat dijadikan sebagai model pembandingan (baseline) dalam penelitian ini.

Hasil tersebut menunjukkan bahwa representasi Word2Vec belum sepenuhnya dapat dimanfaatkan secara maksimal oleh algoritma Decision Tree. Oleh karena itu, penggunaan algoritma lain yang lebih mampu menangani fitur berdimensi tinggi, seperti Random Forest, SVM, atau XGBoost, berpotensi memberikan performa yang lebih baik pada penelitian selanjutnya.

Eksperimen 8: Gaussian Naive Bayes + Word2Vec

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Naïve Bayes (NB) dengan representasi fitur Word2Vec. Metode Word2Vec digunakan untuk mengubah teks deskripsi wine menjadi vektor numerik yang mampu merepresentasikan hubungan semantik antar kata. Vektor hasil transformasi tersebut kemudian digunakan sebagai input dalam proses pelatihan dan pengujian model Naïve Bayes untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
NB + Word2Vec	0.392157	0.607843	0.512691	0.392157	0.370787


Berdasarkan hasil evaluasi, model Naïve Bayes dengan Word2Vec memperoleh accuracy sebesar 39,22% dengan error rate sebesar 60,78%. Nilai precision sebesar 51,27% menunjukkan bahwa prediksi model cukup tepat, namun nilai recall sebesar 39,22% menunjukkan kemampuan model dalam mengenali seluruh kelas masih rendah. Nilai F1-score sebesar 37,08% menunjukkan bahwa performa model secara keseluruhan masih kurang optimal.

Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.38	0.67	0.48	526
Low	0.28	0.56	0.37	337
Medium	0.65	0.21	0.32	1126
Accuracy			0.39	1989
Macro Avg	0.43	0.48	0.39	1989
Weighted Avg	0.51	0.39	0.37	1989

Berdasarkan classification report, kelas High memiliki recall tertinggi sebesar 0,67, yang menunjukkan bahwa model cukup baik dalam mendeteksi wine berkualitas tinggi. Sebaliknya, kelas Medium memiliki recall terendah yaitu 0,21, sehingga masih banyak data Medium yang salah diklasifikasikan ke kelas lain.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 352 data High, 190 data Low, dan 238 data Medium dengan benar. Namun, masih terdapat kesalahan prediksi yang cukup besar, terutama pada kelas Medium yang banyak diprediksi sebagai kelas High maupun Low. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antar kelas kualitas wine.

Interpretasi Model

Secara keseluruhan, kombinasi Naïve Bayes dan Word2Vec mampu melakukan klasifikasi kualitas wine berdasarkan deskripsi teks, namun menghasilkan performa yang lebih rendah dibandingkan beberapa model lainnya dengan nilai accuracy sebesar 39,22%.

Hasil tersebut menunjukkan bahwa asumsi independensi fitur pada Naïve Bayes kurang sesuai untuk merepresentasikan hubungan kompleks yang terdapat pada fitur Word2Vec. Oleh karena itu, kombinasi ini dapat digunakan sebagai model pembanding (baseline), sedangkan penggunaan algoritma lain yang lebih mampu memanfaatkan representasi vektor berpotensi menghasilkan performa yang lebih baik.

Eksperimen 9: Decision Tree + GloVe (Pre-Trained)

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Decision Tree (DT) dengan representasi fitur GloVe (Global Vectors for Word Representation). Metode GloVe digunakan untuk mengubah teks deskripsi wine menjadi vektor numerik berdasarkan hubungan kemunculan kata secara global. Vektor tersebut kemudian digunakan sebagai fitur masukan pada model Decision Tree untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + GloVe	0.464555	0.535445	0.493500	0.464555	0.471476

Berdasarkan hasil evaluasi, model Decision Tree dengan GloVe memperoleh accuracy sebesar 46,46% dengan error rate sebesar 53,54%. Nilai precision sebesar 49,35%, recall sebesar 46,46%, dan F1-score sebesar 47,15% menunjukkan bahwa performa model berada pada kategori sedang dan relatif seimbang.


Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.39	0.52	0.44	526
Low	0.31	0.38	0.34	337
Medium	0.60	0.47	0.52	1126
Accuracy			0.46	1989

Macro Avg	0.43	0.45	0.44	1989
Weighted Avg	0.49	0.46	0.47	1989

Berdasarkan classification report, kelas Medium memiliki performa terbaik dengan nilai F1-score sebesar 0,52, sedangkan kelas Low memiliki performa terendah dengan F1-score sebesar 0,34. Hal ini menunjukkan bahwa model lebih mampu mengenali kelas Medium dibandingkan kelas lainnya.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 271 data High, 129 data Low, dan 524 data Medium dengan benar. Namun, masih terdapat kesalahan prediksi yang cukup besar, terutama pada kelas High dan Medium yang saling tertukar.

Interpretasi Model

Secara keseluruhan, kombinasi Decision Tree dan GloVe menghasilkan performa yang cukup baik dengan nilai accuracy sebesar 46,46% dan F1-score sebesar 47,15%. Hasil ini menunjukkan bahwa representasi GloVe mampu membantu model dalam menangkap informasi semantik dari deskripsi wine.

Meskipun demikian, model masih mengalami kesulitan dalam membedakan beberapa kelas, khususnya pada kelas Low. Oleh karena itu, kombinasi DT + GloVe dapat dijadikan sebagai model pembanding, sementara penggunaan algoritma klasifikasi lain berpotensi meningkatkan performa pada penelitian selanjutnya.

Eksperimen 10: Gaussian Naïve Bayes + GloVe

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Naïve Bayes (NB) dengan representasi fitur GloVe (Global Vectors for Word Representation). GloVe digunakan untuk mengubah teks deskripsi wine menjadi vektor numerik yang merepresentasikan hubungan antar kata berdasarkan statistik kemunculan global. Selanjutnya, vektor tersebut

digunakan sebagai fitur masukan pada model Naïve Bayes untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
NB + GloVe	0.506787	0.493213	0.543340	0.506787	0.509558


Berdasarkan hasil evaluasi, model Naïve Bayes dengan representasi GloVe memperoleh accuracy sebesar 50,68% dengan error rate sebesar 49,32%. Nilai precision sebesar 54,33%, recall sebesar 50,68%, dan F1-score sebesar 50,96% menunjukkan bahwa model memiliki performa yang cukup baik dan lebih seimbang dibandingkan beberapa kombinasi model sebelumnya.

Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.44	0.66	0.53	526
Low	0.36	0.42	0.39	337
Medium	0.65	0.46	0.54	1126
Accuracy			0.51	1989
Macro Avg	0.48	0.51	0.48	1989
Weighted Avg	0.54	0.51	0.51	1989

Berdasarkan classification report, kelas Medium memperoleh F1-score tertinggi sebesar 0,54, sedangkan kelas High memiliki recall tertinggi sebesar 0,66. Sementara itu, kelas Low masih menunjukkan performa yang lebih rendah dibandingkan dua kelas lainnya.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 349 data High, 140 data Low, dan 519 data Medium dengan benar. Namun, masih terdapat sejumlah kesalahan prediksi, terutama pada kelas Medium yang cukup sering diprediksi sebagai High maupun Low.

Interpretasi Model

Secara keseluruhan, kombinasi Naïve Bayes dan GloVe menghasilkan performa yang paling baik dibandingkan kombinasi Naïve Bayes sebelumnya, dengan nilai accuracy sebesar 50,68% dan F1-score sebesar 50,96%. Hal ini menunjukkan bahwa representasi GloVe cukup efektif dalam membantu Naïve Bayes menangkap informasi penting dari teks deskripsi wine.

Meskipun demikian, model masih mengalami kesulitan dalam membedakan kelas Low secara konsisten. Oleh karena itu, kombinasi NB + GloVe dapat dipertimbangkan sebagai salah satu model terbaik pada penelitian ini, khususnya apabila dibandingkan dengan kombinasi NB + Word2Vec yang menghasilkan performa lebih rendah.

Eksperimen 11: Decision Tree + FastText

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Decision Tree (DT) dengan representasi fitur FastText. FastText digunakan untuk mengubah teks deskripsi wine menjadi vektor numerik dengan mempertimbangkan informasi subword sehingga mampu merepresentasikan kata-kata yang jarang muncul maupun memiliki variasi bentuk. Vektor hasil representasi tersebut selanjutnya digunakan sebagai fitur masukan pada model Decision Tree untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + FastText	0.476119	0.523881	0.538034	0.476119	0.478050


Berdasarkan hasil evaluasi, model Decision Tree dengan FastText memperoleh accuracy sebesar 47,61% dengan error rate sebesar 52,39%. Nilai precision sebesar 53,80%, recall sebesar 47,61%, dan F1-score sebesar 47,81% menunjukkan bahwa performa model berada pada kategori sedang dengan keseimbangan yang cukup baik.

Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.42	0.68	0.52	526
Low	0.31	0.44	0.37	337
Medium	0.66	0.39	0.49	1126
Accuracy			0.48	1989
Macro Avg	0.47	0.50	0.46	1989
Weighted Avg	0.54	0.48	0.48	1989

Berdasarkan classification report, kelas High memiliki recall tertinggi sebesar 0,68, yang menunjukkan bahwa model cukup baik dalam mengenali wine berkualitas tinggi. Sementara itu, kelas Medium memiliki precision tertinggi sebesar 0,66, sedangkan kelas Low masih menjadi kelas dengan performa terendah.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 357 data High, 149 data Low, dan 441 data Medium dengan benar. Namun, masih terdapat kesalahan prediksi yang cukup besar, terutama pada kelas Medium yang sering diprediksi sebagai High maupun Low.

Interpretasi Model

Secara keseluruhan, kombinasi Decision Tree dan FastText menghasilkan performa yang sedikit lebih baik dibandingkan kombinasi DT + Word2Vec dan DT + GloVe. Hal ini ditunjukkan oleh nilai accuracy sebesar 47,61% dan F1-score sebesar 47,81%.

Meskipun demikian, model masih mengalami kesulitan dalam membedakan kelas Medium dan Low secara konsisten. Oleh karena itu, kombinasi DT + FastText dapat digunakan sebagai model pembanding, namun masih diperlukan algoritma klasifikasi yang lebih kuat untuk memperoleh performa yang lebih optimal.

Eksperimen 12: Gaussian Naive Bayes + FastText

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Naïve Bayes (NB) dengan representasi fitur FastText. FastText mengubah teks deskripsi wine menjadi vektor numerik dengan memanfaatkan informasi subword sehingga mampu menangkap makna kata dengan lebih baik, termasuk pada kata yang jarang muncul. Representasi vektor tersebut kemudian digunakan sebagai fitur masukan untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
NB + FastText	0.382102	0.617898	0.499829	0.382102	0.362104


Berdasarkan hasil evaluasi, model Naïve Bayes dengan FastText memperoleh accuracy sebesar 38,21% dengan error rate sebesar 61,79%. Nilai precision sebesar 49,98%, recall sebesar 38,21%, dan F1-score sebesar 36,21% menunjukkan bahwa performa model masih tergolong rendah dalam membedakan ketiga kelas kualitas wine.

Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.38	0.66	0.48	526
Low	0.26	0.54	0.35	337
Medium	0.63	0.21	0.31	1126
Accuracy			0.38	1989
Macro Avg	0.42	0.47	0.38	1989
Weighted Avg	0.50	0.38	0.36	1989

Berdasarkan classification report, kelas High memiliki recall tertinggi sebesar 0,66, sedangkan kelas Medium memiliki precision tertinggi sebesar 0,63. Namun, nilai recall kelas Medium yang hanya 0,21 menunjukkan bahwa sebagian besar data Medium masih sulit dikenali oleh model.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 346 data High, 181 data Low, dan 233 data Medium dengan benar. Akan tetapi, masih terdapat banyak kesalahan prediksi, terutama pada kelas Medium yang sering diprediksi sebagai kelas High maupun Low.

Interpretasi Model

Secara keseluruhan, kombinasi Naïve Bayes dan FastText menghasilkan performa yang kurang optimal dengan nilai accuracy sebesar 38,21% dan F1-score sebesar 36,21%. Hasil ini menunjukkan bahwa meskipun FastText mampu menghasilkan representasi teks yang baik, asumsi independensi fitur pada Naïve Bayes belum mampu memanfaatkan representasi tersebut secara maksimal.

Dibandingkan dengan kombinasi NB + GloVe, model NB + FastText menunjukkan performa yang lebih rendah. Oleh karena itu, kombinasi ini lebih sesuai digunakan sebagai model pembanding (baseline) dibandingkan sebagai model utama dalam penelitian ini.

Eksperimen 13: Decision Tree + BERT (Contextual)

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Decision Tree (DT) dengan representasi fitur BERT (Bidirectional Encoder Representations from Transformers). BERT digunakan untuk menghasilkan representasi kontekstual dari deskripsi wine sehingga hubungan antar kata dapat dipahami dengan lebih baik dibandingkan metode embedding konvensional. Representasi vektor hasil ekstraksi BERT kemudian digunakan sebagai fitur masukan untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
DT + BERT	0.518854	0.481146	0.541528	0.518854	0.523587


Berdasarkan hasil evaluasi, model Decision Tree dengan BERT memperoleh accuracy sebesar 51,89% dengan error rate sebesar 48,11%. Nilai precision sebesar 54,15%, recall sebesar 51,89%, dan F1-score sebesar 52,36% menunjukkan bahwa kombinasi ini memiliki performa yang lebih baik dibandingkan beberapa kombinasi embedding sebelumnya.

Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.47	0.57	0.52	526
Low	0.37	0.50	0.43	337
Medium	0.62	0.50	0.56	1126
Accuracy			0.52	1989
Macro Avg	0.49	0.52	0.50	1989
Weighted Avg	0.54	0.52	0.52	1989

Berdasarkan classification report, kelas Medium memperoleh F1-score tertinggi sebesar 0,56 dengan precision 0,62. Kelas High memiliki recall sebesar 0,57, sedangkan kelas Low menunjukkan performa yang cukup seimbang meskipun masih lebih rendah dibandingkan dua kelas lainnya.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 300 data High, 168 data Low, dan 564 data Medium dengan benar. Kesalahan prediksi masih cukup banyak terjadi pada kelas Medium yang diprediksi sebagai High maupun Low, namun jumlah prediksi benar pada kelas Medium juga menjadi yang tertinggi dibandingkan kelas lainnya.

Interpretasi Model

Secara keseluruhan, kombinasi Decision Tree dan BERT menunjukkan performa yang cukup baik dengan nilai accuracy sebesar 51,89% dan F1-score sebesar 52,36%. Hasil ini merupakan peningkatan dibandingkan kombinasi Decision Tree dengan Word2Vec, GloVe, maupun FastText, sehingga menunjukkan bahwa embedding kontekstual dari BERT mampu memberikan informasi yang lebih kaya kepada model klasifikasi.

Meskipun demikian, model masih mengalami kesulitan dalam membedakan beberapa data pada kelas Medium dengan kelas lainnya. Namun, berdasarkan hasil evaluasi yang diperoleh, kombinasi DT + BERT dapat dipertimbangkan sebagai salah satu model dengan performa terbaik pada penelitian ini.

Eksperimen 14: Gaussian Naïve Bayes + BERT

Pada tahap ini dilakukan proses klasifikasi menggunakan algoritma Naïve Bayes (NB) dengan representasi fitur BERT (Bidirectional Encoder Representations from Transformers). BERT digunakan untuk menghasilkan representasi vektor yang bersifat kontekstual sehingga mampu memahami hubungan antar kata berdasarkan konteks kalimat. Representasi vektor hasil ekstraksi BERT selanjutnya digunakan sebagai fitur masukan pada algoritma Naïve Bayes untuk mengklasifikasikan kualitas wine ke dalam kategori Low, Medium, dan High.

Hasil Evaluasi Model

Model	Accuracy	Error Rate	Precision	Recall	F1-score
NB + BERT	0.535948	0.464052	0.563721	0.535948	0.540429


Berdasarkan hasil evaluasi, model Naïve Bayes dengan BERT memperoleh accuracy sebesar 53,59% dengan error rate sebesar 46,41%. Selain itu, model menghasilkan nilai precision sebesar 56,37%, recall sebesar 53,59%, dan F1-score sebesar 54,04%. Hasil ini menunjukkan bahwa kombinasi NB + BERT memiliki kemampuan klasifikasi yang lebih baik dibandingkan sebagian besar kombinasi model dan embedding sebelumnya.

Classification Report

Kelas	Precision	Recall	F1-score	Support
High	0.50	0.61	0.55	526
Low	0.38	0.55	0.45	337
Medium	0.65	0.50	0.56	1126
Accuracy			0.54	1989
Macro Avg	0.51	0.55	0.52	1989
Weighted Avg	0.56	0.54	0.54	1989

Berdasarkan classification report, kelas Medium memperoleh precision tertinggi sebesar 0,65 dan F1-score sebesar 0,56, sedangkan kelas High memiliki recall tertinggi sebesar 0,61. Kelas Low menunjukkan performa yang cukup baik dengan nilai recall sebesar 0,55, meskipun precision-nya masih relatif rendah.

Confusion Matrix



Berdasarkan confusion matrix di atas, model berhasil mengklasifikasikan 319 data High, 187 data Low, dan 560 data Medium dengan benar. Walaupun masih terdapat kesalahan prediksi, terutama pada kelas Medium yang diprediksi sebagai High maupun Low, jumlah prediksi benar pada masing-masing kelas menunjukkan peningkatan dibandingkan beberapa kombinasi model sebelumnya.

Interpretasi Model

Secara keseluruhan, kombinasi Naïve Bayes dan BERT menghasilkan performa terbaik dibandingkan seluruh kombinasi Naïve Bayes dengan embedding lainnya. Hal ini ditunjukkan oleh nilai accuracy sebesar 53,59% dan F1-score sebesar 54,04%, yang merupakan nilai tertinggi pada kelompok model Naïve Bayes.

Kemampuan BERT dalam menghasilkan representasi kontekstual memungkinkan Naïve Bayes memperoleh informasi yang lebih kaya dari deskripsi wine. Oleh karena itu, berdasarkan hasil evaluasi yang diperoleh, kombinasi NB + BERT dapat dianggap sebagai model terbaik dalam penelitian ini, karena mampu memberikan keseimbangan yang baik antara precision, recall, dan F1-score pada ketiga kelas kualitas wine.

Data Balancing Eksperimental: SMOTE vs Back Translation

Pada penelitian ini ditemukan bahwa distribusi kelas pada data latih tidak seimbang. Kelas Medium memiliki jumlah data yang jauh lebih besar dibandingkan kelas Low dan High. Kondisi tersebut dapat menyebabkan model cenderung memprediksi kelas mayoritas sehingga menurunkan kemampuan klasifikasi pada kelas minoritas.

Untuk mengatasi permasalahan tersebut, dilakukan eksperimen menggunakan dua metode penyeimbangan data, yaitu SMOTE (Synthetic Minority Oversampling Technique) dan Back Translation. Tujuan eksperimen ini adalah menentukan metode penyeimbangan yang paling efektif untuk digunakan pada tahap pemodelan selanjutnya.

1. Back Translation sebagai Augmentasi Data Teks

Back Translation merupakan teknik augmentasi data pada Natural Language Processing yang menghasilkan data sintetik melalui proses penerjemahan ke bahasa lain dan diterjemahkan kembali ke bahasa asal. Berbeda dengan SMOTE yang membentuk data sintetis berdasarkan interpolasi numerik, Back Translation menghasilkan variasi teks yang tetap mempertahankan makna semantik sehingga lebih alami secara linguistik.

Pada penelitian ini, deskripsi wine berbahasa Inggris diterjemahkan menggunakan model MarianMT ke beberapa bahasa perantara, kemudian diterjemahkan kembali ke bahasa Inggris untuk menghasilkan data baru.

Tabel Bukti Hasil Back Translation

No	Teks Asli Bahasa Inggris	Teks Hasil Back Translation
1	aroma mineral spice toast yellow apple lemon p...	black cherry plum aroma dry smooth toasted roc...
2	cascina ferrero beautiful linear wine cooling ...	fine soft silky wine elegant mousse bubble qua...
3	supple bursting ripe purple fruit real success...	herbaceous nose full raspberry greenolive dew ...

Berdasarkan tabel tersebut, terlihat bahwa hasil Back Translation menghasilkan variasi kalimat baru yang berbeda secara struktur bahasa, namun tetap mempertahankan konteks dan makna utama dari ulasan wine.

Penambahan Data Latih Akibat Back Translation


Proses Back Translation menghasilkan penambahan jumlah data pada himpunan data latih.

Tabel Jumlah Data Sebelum dan Sesudah Back Translation

Kondisi Data	Jumlah Data
Sebelum Augmentasi	7.952

Sesudah Augmentasi	13.506
--------------------	--------

Gambar Penambahan Data Latih Akibat Back Translation



Berdasarkan gambar tersebut, jumlah data latih meningkat dari 7.952 baris menjadi 13.506 baris setelah dilakukan Back Translation. Penambahan data ini diharapkan dapat membantu model mempelajari pola bahasa yang lebih beragam tanpa kehilangan konteks asli.

2. Demonstrasi Visual Cara Kerja SMOTE


SMOTE merupakan metode oversampling yang bekerja dengan membentuk sampel sintetis baru berdasarkan kedekatan antar data minoritas pada ruang fitur. Berbeda dengan Back Translation yang menghasilkan teks baru, SMOTE menghasilkan vektor numerik sintetis.

Distribusi Data Sebelum dan Sesudah SMOTE

Tabel Distribusi Kelas

Kelas	Sebelum SMOTE	Sesudah SMOTE
Low	1.348	4.502
Medium	4.502	4.502
High	2.102	4.502

Gambar Distribusi Data Sebelum dan Sesudah SMOTE



Berdasarkan gambar tersebut, sebelum proses SMOTE distribusi kelas masih tidak seimbang dengan kelas Medium sebagai kelas mayoritas. Setelah SMOTE diterapkan, seluruh kelas memiliki jumlah data yang sama, yaitu 4.502 data, sehingga rasio distribusi menjadi 1:1:1.

Evaluasi Komparatif SMOTE dan Back Translation

Untuk menentukan metode penyeimbangan terbaik, dilakukan pengujian awal menggunakan kedua pendekatan tersebut. Hasil evaluasi diperoleh sebagai berikut.

Tabel Perbandingan SMOTE dan Back Translation

Metode Penyeimbangan	Akurasi Model
SMOTE (Matematis Vektor)	61,54%
Back Translation (Teks Sintetis)	63,10%

Selain itu, hasil pengujian menunjukkan:

- Akurasi Pure SMOTE = **61,54%**
- Akurasi Pure Back Translation = **63,10%**

Interpretasi Hasil

Berdasarkan hasil eksperimen, metode Back Translation menghasilkan akurasi yang lebih tinggi dibandingkan SMOTE, dengan selisih sebesar 1,56%. Hasil ini menunjukkan bahwa augmentasi berbasis teks lebih efektif dibandingkan oversampling berbasis interpolasi numerik pada kasus klasifikasi ulasan wine.

SMOTE memang mampu menyeimbangkan distribusi kelas secara matematis, namun sampel sintetis yang dihasilkan tidak selalu merepresentasikan struktur linguistik yang alami. Sebaliknya, Back Translation menghasilkan variasi teks baru yang tetap mempertahankan makna semantik sehingga memberikan informasi yang lebih kaya kepada model.

Oleh karena itu, pada eksperimen selanjutnya dalam penelitian ini, metode Back Translation dipilih sebagai teknik penyeimbangan data yang digunakan, sedangkan SMOTE tidak digunakan kembali pada tahap pemodelan akhir.